

Sistem Klasifikasi Pengajuan Kredit Dengan Metode Support Vector Machine (SVM)

I Made Dwi Putra Asana

Program Studi Teknik
Informatika, Fakultas Teknologi
dan Informatika
Institut Bisnis dan Teknologi
Indonesia
Bali, Indonesia

dwiputraasana@instiki.ac.id

Ni Putu Della Tirta Yanti

Program Studi Teknik
Informatika, Fakultas Teknologi
dan Informatika
Institut Bisnis dan Teknologi
Indonesia
Bali, Indonesia

dellatirtayanti@gmail.com

Abstract— Entering the era of the Covid-19 pandemic, lending capital (credit) to KOPPAS has increased, causing a lot of data and slowing down the credit disbursement process. Currently, KOPPAS has not implemented a support system that can provide consideration for credit granting decisions. Therefore, in this study, researchers will discuss the design and development of a decision support application system for granting credit using the Support Vector Machine (SVM) method, to speed up the credit granting process, prevent the level of subjectivity in granting credit, and to minimize the occurrence of bad loans. resulting from errors in the decision-making process. The development of this system uses modeling techniques with data classification processes and the CRISP-DM development method. In this case, the Support Vector Machine method classifies data into 2 classes, namely feasible and infeasible classes. The model development process uses the Radial Basis Function (RBF) kernel parameter by exploring the use of C (cost) and γ (gamma) parameter values. This development model uses 200 data with the attributes used in the form of the loan amount, term, collateral value, guarantor agreement, occupation, and loan history. The use of these attributes and the amount of data can produce quite good performance with the highest accuracy rate of 85% using $C = 1$ and $\gamma = 0.005$ and the distribution of data is 80% training data and 20% testing data. With the performance of this model, the system can classify creditworthiness.

Keywords—SVM, Classification, Credit

I. PENDAHULUAN

Kebutuhan masyarakat akan pinjaman modal mengalami peningkatan sejak memasuki era pandemi covid-19. Hal ini dikarenakan banyak pelaku usaha pariwisata di Bali dirumahkan, sehingga mengalami kesulitan dalam memenuhi kebutuhan maupun dalam hal membangun usaha baru. Oleh karena itu, lembaga keuangan sangat berperan penting dalam proses peminjaman kredit. Namun, seleksi pemberian kredit di masa pandemi ini menjadi tantangan tersendiri bagi setiap lembaga keuangan. Penggunaan komputer sebagai alat bantu untuk mengelola suatu pekerjaan menjadi kebutuhan yang sangat vital dimana informasi cepat dan akurat menjadi suatu hal yang sangat dibutuhkan pada saat ini[1]. Salah satu lembaga keuangan yang memberikan pelayanan peminjaman modal adalah Koperasi. Koperasi merupakan sebuah lembaga usaha yang dimiliki dan dijalankan oleh anggotanya untuk memenuhi kebutuhan bersama baik di bidang ekonomi, sosial ataupun budaya[2]. Salah satu koperasi yang menyediakan jasa simpan pinjam di Kabupaten Tabanan yaitu KOPPAS Budhi Dharma. Di masa pandemi ini, KOPPAS memerlukan bantuan teknologi informasi dalam seleksi pemberian kredit, agar tidak menimbulkan kredit macet akibat gagal bayar di kemudian hari. Pada dasarnya, pemberian kredit merupakan hal yang sangat memiliki resiko tinggi dan dibutuhkan kepercayaan penuh antara pihak kreditur dan debitur, serta sangat berpengaruh terhadap kondisi keuangan dan kelangsungan operasional perusahaan.

Berdasarkan hasil studi lapangan yang dilakukan di Koperasi Pedagang Pasar (KOPPAS) Budhi Dharma, diperoleh informasi rata-rata pencairan kredit per bulan mencapai 1 milyar, dengan jumlah pengajuan kredit per hari mencapai 5-8 data pengajuan yang masuk pada KOPPAS. Banyaknya pemohon kredit membuat karyawan cukup

kewalahan dalam proses pertimbangan pemberian kredit, karena harus melalui beberapa tahap pengecekan data oleh *credit analyst* hingga sampai ke manajer untuk pengambilan keputusan. Jika hal tersebut terus berlanjut dengan pemohon kredit yang semakin mengalami peningkatan, akan menyebabkan terjadinya penumpukan data permohonan kredit yang masuk. Sebagai alternatif informasi lain dalam pengambilan keputusan, peneliti dalam penelitian ini mengusulkan sistem aplikasi pendukung keputusan pemberian kredit dengan menggunakan metode *Support Vector Machine* (SVM). Metode SVM dapat digunakan dalam memecahkan permasalahan penilaian kredit, karena metode ini mampu menggeneralisasi data dengan baik, mampu melakukan pengolahan data dengan jumlah besar, mampu melakukan klasifikasi dan regresi secara linier dan *non* linier, serta dapat menghasilkan akurasi yang signifikan dengan daya komputasi yang lebih sedikit.

Beberapa penelitian yang mendukung dalam penggunaan metode SVM yaitu penelitian yang dilakukan oleh Rizqi Agung Permana dan Sucitra Sahara pada tahun 2019, dengan judul “*Metode Support Vector Machine* Sebagai Penentu Kelulusan Mahasiswa pada Pembelajaran Elektronik”. Permasalahan dalam penelitian ini adalah kegagalan dan kesuksesan akademi pelaksanaan pembelajaran *E-learning* sulit diprediksi dan merupakan bagian dari mahasiswa yang telah menjadi subyek dari perdebatan. Berdasarkan pengolahan data yang sudah dilakukan dengan membandingkan algoritma *Support Vector Machine* dengan menggunakan data log mahasiswa, kemudian di uji untuk mendapatkan nilai *accuracy* dan AUC dari setiap algoritma sehingga didapat hasil pengujian tertinggi dengan menggunakan *support vector* dengan nilai *accuracy* sebesar dengan akurasi 85.02%, dan nilai AUC 0.610. Hasil pengujian ini membuktikan bahwa SVM memiliki kemampuan generalisasi yang sangat baik untuk memecahkan masalah walaupun dengan sampel yang terbatas [3].

Penelitian kedua dilakukan oleh Emy Haryatmi dan Sheila Pramita Hervianti pada tahun 2021, dengan judul “Penerapan Algoritma *Support Vector Machine* Untuk Model Prediksi Kelulusan Mahasiswa Tepat Waktu”. Permasalahan dalam penelitian ini adalah dibutuhkannya sistem prediksi yang mampu memberikan prediksi terhadap kelulusan mahasiswa secara dini untuk meningkatkan jumlah kelulusan mahasiswa dan meminimalisir jumlah mahasiswa yang tidak lulus tepat waktu sesuai dengan masa studinya pada Fakultas Teknik Universitas Swasta di Indonesia. Berdasarkan dari hasil pengujian terhadap 3 kelompok persentase data *training* dan data *testing*, algoritma SVM memberikan nilai akurasi paling tinggi terhadap data *testing* yaitu sebesar 94,4% dengan persentase data *training* dan data *testing* sebesar 90% dan 10%. Nilai akurasi dari presentase data *training* dan data *testing* sebesar 80% dan 20% adalah 92,6%. Nilai akurasi dari presentase data *training* dan data *testing* sebesar 70% dan 30% adalah 91,4%. Hal ini menandakan bahwa tingkat kedekatan antara nilai prediksi dan nilai aktual mendekati 100% sehingga data *training* dan data *testing* yang digunakan dapat dikatakan valid [4].

Penelitian ketiga dilakukan oleh Akbar Habib Buana Wibawa Putra, Anisa Herdiani, dan Ibnu Asror pada tahun 2019, dengan judul “Identifikasi *Fake Account* Twitter Menggunakan *Support Vector Machine*”. Sistem yang dibangun diperlukan karena banyak akun palsu yang digunakan untuk menambah popularitas seseorang dengan menggunakan *followers* palsu atau *fake followers*. Pengumpulan data yang akan dilakukan menggunakan *library Tweepy* pada Python. Hasil penelitian ini *fake account* dapat diidentifikasi dengan menggunakan metode SVM (*Support vector machine*) dengan menghasilkan *accuracy* sebesar 93.42% jika menggunakan seluruh atribut jumlah tweet, memakai twitter untuk Android, pemakaian twitter untuk web, Geolokasi, status *protected* atau status *verified* [5].

Penelitian keempat dilakukan oleh Rooy Thaniket, Kusrini, dan Emha Taufik Lutfi, dengan judul “Prediksi Kelulusan Mahasiswa Tepat Waktu Menggunakan Algoritma *Support Vector Machine*”. Permasalahan dalam penelitian ini yaitu jumlah kelulusan

mempengaruhi penilaian pemerintah serta mempengaruhi status akreditasi program studi tingkat kelulusan dalam suatu perguruan tinggi, itu sangat penting bagi setiap mahasiswa. Dalam hal ini peneliti melakukan perbandingan hasil penelitian dari beberapa contoh penelitian untuk memprediksi tingkat kelulusan mahasiswa dengan melihat tingkat akurasi yang dihasilkan dari pengujian sistem. Penelitian ini menggunakan SVM dengan memanfaatkan *library* sklearn pada Python dengan menggunakan parameter tipe kernel *Radial basis function* (RBF). Hasil akhir dari penelitian ini yaitu tingkat akurasi yang dimiliki oleh algoritma *Support Vector Machine* dengan tipe kernel RBF untuk memprediksi kelulusan mahasiswa dengan menggunakan python sebesar 95,00% [6].

Penelitian kelima dilakukan oleh Oki Arifin dan Theopilus Bayu Sasongko pada tahun 2018, dengan judul “Analisa Perbandingan Tingkat Performansi Metode *Support Vector Machine* dan *Naïve Bayes Classifier* Untuk Klasifikasi Jalur Minat SMA”. Pada penelitian ini digunakan data dari dua sekolah SMA sebanyak 288 siswa tahun ajaran 2013-2014. Siswa yang berlabel IPA berjumlah 150 siswa dan siswa yang berlabel jurusan IPS berjumlah 138 siswa. Dataset terdiri dari data nilai psikologi (iq, logika rasional, konkrit operasional, abstrak konseptual, analisa sintesa, logika verbal, logika numerik, dan daya ingat), Nilai UN pada jenjang sebelumnya (Matematika dan IPA) dan nilai rata-rata raport kelas X (IPA dan IPS) yang diambil dari SMA di Jawa Tengah. Hasil akhir dari proses klasifikasi kedua metode tersebut diperoleh kesimpulan bahwa tingkat performansi yang diukur dengan akurasi, presisi, *recall*, dan nilai AUC (*area under curve*) algoritma SVM yang menggunakan kernel anova dan faktor pinalti (C) sebesar 5.0 lebih besar daripada performansi algoritma *Naïve Bayes Classifier*. Dimana dengan menggunakan metode SVM menghasilkan tingkat akurasi sebesar 97.1%, sedangkan klasifikasi dengan metode *Naïve Bayes* menghasilkan tingkat akurasi sebesar 90.86% [7].

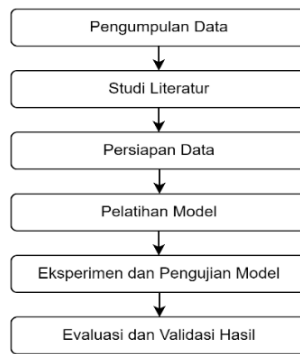
Penelitian keenam dilakukan oleh Suhardjono, Ganda Wijaya, dan Abdul Hamid pada tahun 2019, dengan judul “Prediksi Waktu Kelulusan Mahasiswa Menggunakan SVM Berbasis PSO”. Pada penelitian tersebut menggunakan dataset mahasiswa yang diambil dari tahun 2013-2018 sebanyak 796 parameter dengan sembilan atribut yang diuji menggunakan algoritma SVM berbasis PSO. Dalam penelitian ini menggunakan 10-*cross validation* untuk melakukan uji validasi terhadap model. Jika terdapat atribut yang tidak optimal akan digunakan model PSO untuk mengoptimalkan tingkat akurasi. Hasil dari eksperimentasi dengan menggunakan metode SVM yaitu akurasi sebesar 85.81% [8].

Dari beberapa penelitian tersebut, dapat disimpulkan bahwa metode SVM merupakan metode yang sangat baik digunakan dalam proses pengolahan data dengan proses klasifikasi maupun prediksi. Dengan pembangunan aplikasi ini, diharapkan dapat membantu KOPPAS Budhi Dharma dalam menentukan pemohon kredit yang layak dan tidak layak mendapatkan kredit dengan sistem komputerisasi yang memungkinkan dalam penghematan biaya serta waktu dalam pengambilan keputusan.

II. METODE PENELITIAN

A. Alur Penelitian

Adapun gambaran alur proses atau tahapan penelitian yang digunakan dalam penelitian ini yaitu dapat dilihat dalam gambar di bawah ini.

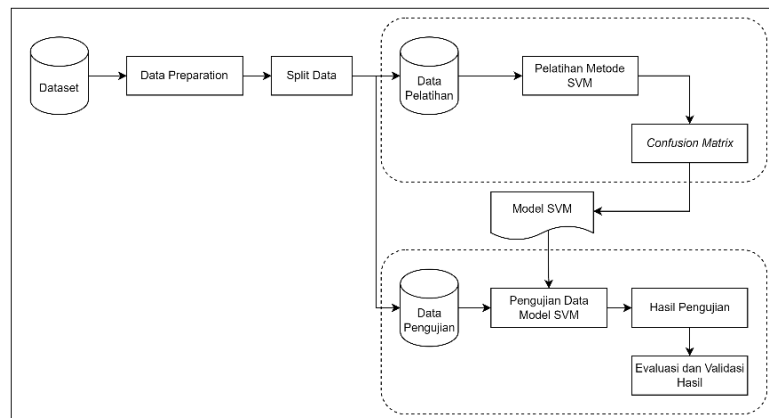


Gambar 1. Alur Penelitian

Pada gambar 1 merupakan alur dari penelitian ini. Alur penelitian dimulai dari melakukan pengumpulan data, dimana data yang digunakan yaitu data pengajuan kredit dari Koperasi Pedagang Pasar (KOPPAS) Budhi Dharma. Selanjutnya peneliti juga mencari studi literatur yang berkaitan dengan metode pengumpulan data pustaka, membaca dan mencatat, serta mengelola bahan penelitian, selanjutnya dilakukan persiapan data yang akan digunakan dalam proses pelatihan model dengan metode pengembangan CRISP-DM. Dalam tahap pengujian akan menggunakan metode *confusion matrix*, setelah itu peneliti melakukan evaluasi dan validasi hasil pengujian.

B. Gambaran Umum Sistem

Perancangan sistem klasifikasi kelayakan kredit pada KOPPAS Budhi Dharma dengan metode *Support Vector Machine* dibuat dalam bentuk rancangan diagram gambaran umum seperti yang terlihat pada gambar 2.




Gambar 2. Gambaran Umum Sistem

Pada sistem yang akan dibangun, terdapat dua proses utama yaitu proses pelatihan dan pengujian dengan menggunakan data pengajuan kredit. Data pengajuan kredit terdiri dari nama, alamat, jenis kelamin, jumlah pinjaman, jangka waktu, nilai jaminan, persetujuan penanggung kredit, pekerjaan, serta riwayat meminjam. Pada langkah pertama pada dataset akan dilakukan proses *preparation* data, dimana proses ini, data yang digunakan akan disaring dan diolah untuk menghilangkan *duplicate* data, *noise*, serta *missing value* sehingga hanya menyisakan atribut yang digunakan dalam proses klasifikasi. Atribut tersebut terdiri dari jumlah pinjaman, nilai jaminan, jangka waktu, persetujuan penanggung kredit, pekerjaan, serta riwayat meminjam. Tahap preparation juga dilakukan untuk mengubah data mentah ke dalam bentuk yang lebih mudah dipahami oleh sistem. Proses ini penting dilakukan karena data mentah sering kali tidak memiliki format yang

teratur dan sulit untuk dikenali oleh sistem. Selanjutnya data yang sudah melalui proses preparation akan melalui proses split data dengan membagi data menjadi data pelatihan dan pengujian. Selanjutnya dilakukan proses pelatihan data dengan metode SVM untuk menghasilkan model yang diharapkan. Kemudian data akan melalui proses pengujian menggunakan metode *confusion matrix* untuk menghasilkan model terbaik. Model yang dihasilkan akan melalui proses pengujian dengan metode SVM menggunakan data uji. Hasil dari proses pengujian, akan melalui proses evaluasi dan validasi hasil untuk menentukan akurasi dan performa terbaik.

C. Support Vector Machine (SVM)

SVM merupakan salah satu algoritma klasifikasi yang dikembangkan oleh Boser, Guyon dan Vapnik yang digunakan untuk memisahkan data berdasarkan 2 kelas berbeda melalui garis optimal *hyperplane*[9]. *Support Vector Machine* (SVM) adalah metode learning machine yang bekerja atas prinsip *Structural Risk Minimization* (SRM) dengan tujuan menemukan *hyperplane* terbaik yang memisahkan dua buah *class* pada *input space*. [10]. Model algoritma SVM merupakan salah satu algoritma dari metode klasifikasi, yang bekerja dengan cara mencari suatu garis (*hyperplane*) untuk memisahkan dua kelompok data. *Hyperplane* dengan pemisah terbaik dapat ditemukan dengan mengukur *margin* dari *hyperplane* dan mencari titik maksimum. Kernel harus digunakan untuk mencapai keberhasilan banyak algoritma klasifikasi untuk permukaan linier. Dengan demikian dapat diketahui bahwa jenis kernel dapat mempengaruhi hasil klasifikasi yang dilakukan. *Hyperplane* adalah garis pemisah terbaik antara dua kelas. Untuk mencari *hyperplane* dapat dilakukan dengan mencari *margin hyperplane* dan mencari titik maksimum. *Margin* adalah jarak antara data terdekat di antara dua kelas yang berbeda, yang disebut dengan *support vector* [11].



Gambar 3. Support Vector Machine

D. Confusion Matrix

Confusion matrix adalah matrix 2x2 yang merepresentasikan hasil klasifikasi biner pada suatu dataset. Terdapat beberapa rumus umum yang dapat digunakan untuk menghitung performa klasifikasi. Hasil dari nilai *accuracy*, *precision* dan *recall* bisa ditampilkan dalam persentase [12]. Untuk melihat hasil dari kinerja model, digunakan metode *confusion matrix* yang terdiri dari *accuracy*, *precision*, dan *recall*. Pada metode ini ditentukan pula target *name* yang digunakan. Dimana target *name* terdiri dari kelas 0 (tidak layak) dan kelas 1 (layak).

III. HASIL DAN PEMBAHASAN

A. Pengolahan Data

Pengolahan data adalah suatu proses menerima data sebagai masukan (input) memproses (processing) menggunakan proses tertentu, dan mengeluarkan hasil proses data tersebut dalam bentuk informasi (output)[13]. Dalam proses pembangunan model ini, data yang digunakan adalah data yang diperoleh dari Koperasi Pedagang Pasar

(KOPPAS) Budhi Dharma, dimana data tersebut berupa data pengajuan kredit tahun 2019 sampai 2021 yang terdiri dari pengajuan yang diterima dan yang ditolak oleh perusahaan yang berjumlah 200 data. Dalam data tersebut memuat beberapa atribut yaitu nama, alamat, jenis kelamin, jumlah pinjaman, jangka waktu, nilai jaminan, persetujuan penanggung kredit, pekerjaan, serta riwayat meminjam. Data tersebut disimpan dalam file berformat .csv agar mampu terbaca oleh sistem saat melakukan proses pemodelan.

index	Nama	Alamat	JenisKelamin	JumlahPinjaman	JangkaWaktu	NilaiJaminan	Penanggung	Pekerjaan	Riwayatmeminjam	Keterangan
0	IPutuAnggaSetiawan	BuahanUtara	L	6000000	12	7000000	1	Pedagang	PemahLancar	1
1	NIPutuRezaJunitaDewi	BonganKaoh	P	5000000	12	6000000	1	Pedagang	PemahLancar	1
2	IGedeDaAdriyanaPutra	BanjarAnyar	L	3000000	6	5000000	1	Pedagang	PemahLancar	1
3	PutuYuliani	Kediri	P	2500000	6	5000000	1	Swasta	BelumPemah	1
4	IPutuGedePandeNarendra	SelamadagTimur	L	4000000	9	6000000	1	Swasta	PemahLancar	1
5	IMadeWarmika	Serampangan	L	3500000	6	6000000	1	Pedagang	BelumPemah	1
6	PutuNovitaDyahWidyasari	Serampangan	P	6000000	12	7000000	1	Pedagang	PemahLancar	1
7	PutuGisellaLaksmitaGauri	Serampangan	P	5000000	12	6000000	1	Pedagang	PemahLancar	1
8	IGedePutuPurwita	Serampangan	L	4000000	9	5000000	1	Pedagang	PemahLancar	1
9	NiluhHudiani	Kediri	P	5000000	12	6000000	1	Pedagang	BelumPemah	1
10	NIPutuKyuChandraDewi	BuahanUtara	P	3500000	6	5000000	1	Swasta	BelumPemah	1
11	IGedePutuSuandana	BuahanUtara	L	4500000	9	6000000	1	Pedagang	PemahLancar	1
12	NIWayanSerimben	BonganPala	P	5000000	12	6200000	1	Pedagang	PemahLancar	1
13	IGedeAriawan	Bakisan	L	4000000	9	5000000	1	Pedagang	PemahLancar	1
14	NIMadeElySuryatmini	Dentantas	P	3500000	6	5000000	1	Pedagang	BelumPemah	1
15	IGedePutuJuliaAdiWijaya	DukuhTabanan	L	7000000	24	8200000	1	Pedagang	BelumPemah	1
16	NiketusSudarmi	Buahan	P	4500000	9	5000000	1	Pedagang	PemahLancar	1
17	IMadeArthaMahajaya	DukuhBuahan	L	4000000	6	5000000	1	Pedagang	BelumPemah	1

Gambar 4. Data Pengajuan Kredit

Data yang telah berformat .csv tersebut akan di-import kedalam google colab untuk diproses sebelum ke tahap pemodelan. Setelah di impor, data di cek kembali untuk memastikan data yang digunakan sudah lengkap. Pada proses ini, terdapat 3 data yang tidak lengkap (*missing*). Data yang tidak lengkap tersebut, diperbaiki secara manual pada file excel sesuai dengan isian form pengajuan yang diisi oleh calon nasabah. Kemudian, dilanjutkan dengan proses encoder data. Encoder data dilakukan dengan tujuan merubah data yang berbentuk kategorikal ke dalam bentuk numerik. Hal ini terjadi karena pada tahap pemodelan hanya mengolah data yang berbentuk numerik. Adapun fitur yang melalui proses encoding yaitu pekerjaan, persetujuan penanggung, dan riwayat meminjam.

```
#untuk merubah nilai menggunakan encoding
from sklearn.preprocessing import LabelEncoder
encoder = LabelEncoder()
dataset['Pekerjaan'] = encoder.fit_transform(dataset['Pekerjaan'])
dataset['Ppenanggung'] = encoder.fit_transform(dataset['Ppenanggung'])
dataset['Riwayatmeminjam'] = encoder.fit_transform(dataset['Riwayatmeminjam'])
```

Dalam proses pemodelan hanya menggunakan beberapa fitur, diantaranya jumlah pinjaman(3), jangka waktu(4), nilai jaminan(5), persetujuan penanggung(6), pekerjaan(7), serta riwayat meminjam(8). Sedangkan untuk labelnya akan menggunakan kolom keterangan(9). Untuk melakukan proses pemilihan fitur untuk proses pemodelan, dapat menggunakan perhitungan array.

```
X_train = dataset.iloc[:, [ 3, 4, 5, 6, 7, 8]].values #menentukan feature (X) yang akan digunakan
y_train = dataset.iloc[:, 9].values #menentukan target (y) dari data yang telah di upload
print(y_train)
```

Kemudian, dataset melalui proses data splitting. Splitting ini berfungsi untuk membagi data menjadi 2 yaitu untuk proses training dan proses pengujian. Penggunaan parameter random state juga sangat berpengaruh dalam hasil akurasi sistem. Random state berfungsi untuk melakukan pengacakan terhadap data yang digunakan. Seperti yang diutarakan oleh Andi Ainun Dzariah Halima dan Siska Anraenia pada tahun 2019, Random state digunakan agar dataset tidak berubah-ubah, sehingga diberikan nilai ketetapan[14]. Pada pembangunan model ini menggunakan split data pengujian sebesar 0.2 (20%) atau 80% data latih dari jumlah keseluruhan 200 data serta dengan random state 20.

```
# Splitting the dataset into the Training set and Test set
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X_train, y_train, test_size =
0.2, random_state = 20)
```

Pembagian data (splitting) serta penggunaan nilai random state dengan persentase yang berbeda sangat berpengaruh dalam hasil akhir model. Baik dalam tingkat akurasi maupun dalam hal performa model yang dihasilkan.

B. Proses Pelatihan Support Vector Machine

Pada proses pembangunan model ini menggunakan metode *Support Vector Machine* (SVM). Seperti yang diutarakan oleh Nuraeni Herlinawati, Yuri Yuliani, Siti Faizah, Windu Gata, dan Samudi pada tahun 2019, dimana metode SVM adalah metode yang baik digunakan untuk klasifikasi dan regresi yang biasa digunakan untuk masalah linear dan non linear[15]. Proses pemodelan dilakukan dengan cara memanggil data training untuk proses pembuatan model. Dalam proses pemodelan ini juga menambahkan parameter kernel di dalamnya. Proses pemodelan ini menggunakan kernel Radial Basis Function (RBF) dengan melakukan eksplorasi terhadap penggunaan nilai parameter C (cost) dan γ (gamma). Pada proses training ini menggunakan parameter $C=1$, dan $\gamma=0.005$.

```
# Fitting the classifier to the Training set
from sklearn.svm import SVC
classifier = SVC(kernel = 'rbf', C= 1, gamma= 0.005)
classifier.fit(X_train, y_train)
print(classifier)
print(y_train)
```

Setelah melakukan proses training atau pelatihan, model kembali di evaluasi menggunakan data uji yang telah disiapkan sebelumnya. Proses pengujian ini bertujuan untuk mengukur kinerja model. Apakah model sudah mampu melakukan prediksi dengan baik atau tidak.

```
# Predicting the Test set results
y_pred = classifier.predict(X_test)
print (X_test)
```

Adapun hasil dari kinerja model yang diukur dengan metode confusion matrix dengan hasil splitting 20% data uji serta penggunaan nilai parameter $C=1$, $\gamma=0.005$ menghasilkan nilai akurasi rata-rata 85%, presisi 91%, dan recall 79% dapat dilihat pada gambar berikut:

	precision	recall	f1-score	support
0	0.81	1.00	0.90	26
1	1.00	0.57	0.73	14
accuracy			0.85	40
macro avg	0.91	0.79	0.81	40
weighted avg	0.88	0.85	0.84	40

Gambar 5. Data Pengajuan Kredit

C. Tampilan Rekomendasi Kredit

Sistem Klasifikasi Pengajuan Kredit KOPPAS Budhi Dharma

Nama	Alamat	Jenis Kelamin	Jumlah Pinjaman	Jangka Waktu	Nilai Jaminan	Per. Penanggung	Pekerjaan	Riwayat Meminjam	Keterangan
IGedeEkaAdnyanaPutra	BarajarAnyar	L	3000000	6	5000000	1	2.0	2	Layak
IPutuAnggaSetiawan	BuahanUtara	L	6000000	12	7000000	1	2.0	2	Layak
IPutuGedePandeNarendra	SelemadegTimur	L	4000000	9	6000000	1	1.0	2	Layak
NIPutuRezaJunitaDewi	BonganKauh	P	5000000	12	6000000	1	2.0	2	Layak
PutuYuliani	Kediri	P	2500000	6	5000000	1	1.0	1	Layak
SanaMade	mengwi	L	2500000	9	4000000	0	1.0	0	Layak
SarkuWayan	selemadeg	L	5500000	12	4500000	0	2.0	0	Tidak Layak

Gambar 6. Tampilan Rekomendasi Kredit

Gambar 4 merupakan tampilan dari sistem rekomendasi kredit yang dibangun. Dimana dalam sistem ini berisikan tabel dengan fitur berupa nama, alamat, jenis kelamin, jumlah pinjaman, jangka waktu, nilai jaminan, persetujuan penanggung, pekerjaan, riwayat meminjam, serta keterangan. Untuk proses *impor* data dilakukan dengan klik *button browse* untuk mengambil data yang telah berformat csv. Selanjutnya data yang telah diambil diklasifikasi dengan model yang telah ditanam ke dalam *flask* dengan cara klik *submit* pada sistem sehingga mampu menghasilkan keterangan layak atau tidak layak mendapatkan kredit. Pada menu ini juga dapat meng-copy hasil dari klasifikasi, mendownload *file* format csv, Excel, dan PDF. Hasil dari klasifikasi sistem ini juga dapat langsung di *print* dengan klik *button print* pada sistem. Pada sistem juga terdapat fitur *search* untuk membantu memudahkan pengguna untuk mencari data calon nasabah.

D. Pengujian Sistem

Pada pembangunan model ini dilakukan proses pengujian dengan melakukan 5 kali *splitting* data serta melakukan pengujian terhadap penggunaan kernel *Radial Basis Function* (RBF) dengan menggunakan beberapa ukuran parameter *C (cost)* y (*gamma*). Pada pengujian ini menghasilkan tingkat akurasi yang berbeda berdasarkan ukuran *splitting* data serta ukuran parameter *cost* dan *gamma*. Hasil pengujian tersebut dapat dilihat pada tabel berikut:

Tabel 1.
Penguujian Sistem

Parameter RBF	<i>Splitting</i>	Akurasi	Presisi	<i>Recall</i>
C = 1 y = 0.005	1	85%	91%	79%
	2	84%	90%	76%
	3	80%	88%	75%
	4	76%	85%	73%
	5	75%	84%	73%
C = 1 y = 0.05	1	85%	91%	79%
	2	82%	89%	74%
	3	78%	87%	73%
	4	74%	84%	71%
	5	75%	84%	73%
C = 1 y = 0.5	1	82%	89%	75%
	2	80%	88%	71%
	3	77%	86%	71%
	4	73%	84%	69%
	5	74%	84%	72%
C = 1 y = 1	1	82%	89%	75%
	2	80%	88%	71%
	3	77%	86%	71%
	4	73%	84%	69%
	5	71%	83%	69%
C = 1 y = 5	1	82%	89%	75%
	2	34%	17%	50%
	3	40%	20%	50%
	4	44%	22%	50%
	5	69%	82%	66%
C = 2 y = 0.005	1	85%	91%	79%
	2	84%	90%	76%
	3	80%	88%	75%
	4	76%	85%	73%
	5	75%	84%	73%

Pada tabel 1 merupakan tabel hasil pengujian data dengan menggunakan parameter kernel RBF dengan rentang nilai C (*cost*) =1 dan nilai y (*gamma*) = 0.005 - 5. Pengujian data ini dilakukan dengan cara melakukan *splitting* terhadap 200 data sebanyak 5 kali dengan pembagian data latih dan data uji dengan proporsi yang berbeda di setiap pengujiannya. Pada *splitting* 1 menggunakan data latih sebesar 80% dan data uji 20%, *splitting* 2 menggunakan data latih 75% dan 25% data uji, *splitting* 3 menggunakan 70% data latih dan 30% data uji, *splitting* 4 menggunakan 65% data latih dan 35% data uji, serta *splitting* 5 menggunakan 60% data latih dan 40% data uji.

Dari hasil pengujian diatas, dapat disimpulkan bahwa performa model terbaik dihasilkan dari penggunaan kernel RBF dengan nilai parameter C=1 dan y (*gamma*) = 0.005, dengan menggunakan *splitting* data 80% data latih dan 20% data uji yang menghasilkan tingkat akurasi tertinggi yaitu 85%, presisi 91%, dan recall 79%. Hasil pemodelan dengan performa terbaik ini selanjutnya disimpan dan ditanam ke dalam tampilan sistem dengan menggunakan flask, sehingga mampu melakukan proses klasifikasi untuk menentukan calon debitur yang layak atau tidak layak mendapatkan kredit.

IV. KESIMPULAN

Tahap rancang bangun sistem klasifikasi kelayakan kredit, dimulai dari pengumpulan data, perancangan sistem, dan pembangunan model dengan menggunakan *google colab*. Metode yang digunakan dalam pembangunan sistem yaitu metode *Support Vector*

Machine dengan tahap pengembangan sistem CRISP-DM. Pembangunan sistem ini menggunakan aplikasi perangkat lunak *Visual Studio Code*, dengan bahasa pemrograman python, HTML, dan CSS. Pada proses *training*, penggunaan parameter sangat berpengaruh dalam poses menghasilkan model. Dalam pembangunan model ini menggunakan parameter kernel *Radial Basis Function* (RBF) dengan melakukan eksplorasi nilai dari parameter C (*cost*) dan γ (*gamma*). Dari hasil eksplorasi tersebut menghasilkan model terbaik dengan nilai parameter $C=1$ dan γ (*gamma*) = 0.005.

Berdasarkan hasil dari proses *training* dalam pembangunan model, dilakukan pengukuran terhadap performa kinerja model dengan menggunakan metode *confusion matrix* dengan menghasilkan akurasi sebesar 85%, presisi 91%, serta *recall* 79%.

Penelitian ini tentunya masih memiliki keterbatasan yaitu hanya menggunakan 200 data dengan 6 atribut yang digunakan dalam proses klasifikasi. Pengembangan yang dapat dilakukan pada penelitian selanjutnya yaitu menambahkan beberapa fitur dan jumlah data yang mungkin saja dapat mempengaruhi kinerja model agar menghasilkan performa yang lebih baik lagi dalam melakukan klasifikasi kelayakan kredit serta dapat meningkatkan akurasi pada model.

REFERENCES

- [1] M. Samsudin, M. Abdurahman, and M. H. Abdullah, "Sistem Informasi Pengkreditan Nasabah Pada Koperasi Simpan Pinjam Sejahtera Baru Kota Ternate Berbasis Web," *J. Ilm. Ilk. - Ilmu Komput. Inform.*, vol. 2, no. 1, pp. 11–23, 2019, doi: 10.47324/ilkominfo.v2i1.16.
- [2] H. Salsabila and E. Sudarmilah, "Sistem Informasi Simpan Pinjam di Koperasi Pendidikan Wonogiri," *J. Repos.*, vol. 2, no. 5, pp. 541–552, 2020, doi: 10.22219/repositor.v2i5.911.
- [3] R. A. Permana and S. Sahara, "Metode Support Vector Machine Sebagai Penentu Kelulusan Mahasiswa pada Pembelajaran Elektronik," vol. VII, no. 1, pp. 50–58, 2019.
- [4] E. Haryatmi and S. Pramita Hervianti, "Penerapan Algoritma Support Vector Machine Untuk Model Prediksi Kelulusan Mahasiswa Tepat Waktu," *J. RESTI (Rekayasa Sist. dan Teknol. Informasi)*, vol. 5, no. 2, pp. 386–392, 2021, doi: 10.29207/resti.v5i2.3007.
- [5] A. Putra, A. Herdiani, and I. Asror, "Identifikasi Fake Account Twitter Menggunakan Support Vector Machine," *eProceedings ...*, vol. 6, no. 2, pp. 8852–8858, 2019.
- [6] rooy Kusni, "Prediksi Kelulusan Mahasiswa Tepat Waktu," vol. 13, no. 2, pp. 69–83, 2019.
- [7] O. Arifin and T. B. Sasongko, "Analisa perbandingan tingkat performansi metode support vector machine dan naïve bayes classifier," *Semin. Nas. Teknol. Inf. dan Multimed. 2018*, vol. 6, no. 1, pp. 67–72, 2018.
- [8] Suhardjono, W. Ganda, and H. Abdul, "Prediksi Waktu Kelulusan Mahasiswa Menggunakan Svm Berbasis Pso," *Bianglala Inform.*, vol. 7, no. 2, pp. 97–101, 2019.
- [9] W. Widayani and H. Harliana, "Analisis Support Vector Machine Untuk Pemberian Rekomendasi Penundaan Biaya Kuliah Mahasiswa," *J. Sains dan Inform.*, vol. 7, no. 1, pp. 20–27, 2021, doi: 10.34128/jsi.v7i1.268.
- [10] I. Sugiyarto, "Perbandingan Kinerja Algoritma Data Mining Prediksi Persetujuan Kartu Kredit," *Fakt. Exacta*, vol. 12, no. 3, p. 180, 2019, doi: 10.30998/faktorexacta.v12i3.4310.
- [11] I. I. Aditia, R. Latuconsina, and A. Dinimaharawati, "SISTEM PENDUKUNG KEPUTUSAN PEMILIHAN TEMPAT KERJA DECISION SUPPORT SYSTEM

- OF INTERNSHIP WORKPLACE SELECTION FOR ELECTRICAL ENGINEERING FACULTY STUDENT ' S OF TELKOM UNIVERSITY,” vol. 8, no. 5, pp. 6725–6736, 2021.
- [12] L. A. Andika, P. A. N. Azizah, and R. Respatiwan, “Analisis Sentimen Masyarakat terhadap Hasil Quick Count Pemilihan Presiden Indonesia 2019 pada Media Sosial Twitter Menggunakan Metode Naive Bayes Classifier,” *Indones. J. Appl. Stat.*, vol. 2, no. 1, p. 34, 2019, doi: 10.13057/ijas.v2i1.29998.
 - [13] R. Kurniawan and S. Marhamelda, “Sistem Pengolahan Data Peserta Didik Pada Lkp Prima Tama Komputer Dumai Dengan Menggunakan Bahasa Pemrograman Php,” *I N F O R M a T I K a*, vol. 11, no. 1, p. 37, 2019, doi: 10.36723/juri.v11i1.140.
 - [14] A. A. D. Halim and S. Anraeni, “Analisis Klasifikasi Dataset Citra Penyakit Pneumonia menggunakan Metode K-Nearest Neighbor (KNN),” *Indones. J. Data Sci.*, vol. 2, no. 1, pp. 01–12, 2021, doi: 10.33096/ijodas.v2i1.23.
 - [15] N. Herlinawati, Y. Yuliani, S. Faizah, W. Gata, and S. Samudi, “Analisis Sentimen Zoom Cloud Meetings di Play Store Menggunakan Naïve Bayes dan Support Vector Machine,” *CESS (Journal Comput. Eng. Syst. Sci.)*, vol. 5, no. 2, p. 293, 2020, doi: 10.24114/cess.v5i2.18186.